



上海交通大学学位论文

**基于多模态知识蒸馏的
轻度认知障碍语音筛查研究**

姓 名：刘逸飞

学 号：522031910023

导 师：洪义

学 院：计算机学院

专业名称：计算机科学与技术

申请学位层次：学士

2026 年 05 月

A Dissertation Submitted to
Shanghai Jiao Tong University for the Degree of Bachelor

RESEARCH ON SPEECH SCREENING FOR MILD
COGNITIVE IMPAIRMENT BASED ON
MULTIMODAL KNOWLEDGE DISTILLATION

Author: Liu Yifei
Supervisor: Hong Yi

School of Computer Science
Shanghai Jiao Tong University
Shanghai, P.R. China
May, 2026

上海交通大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，已在文中以适当方式予以致谢。若在论文撰写过程中使用了人工智能工具，本人已遵循《上海交通大学关于在教育教学中使用 AI 的规范》，确保人工智能生成内容的应用场景、引用范围及标注方式均符合规定，并杜绝学术不端行为。本人完全知晓本声明的法律后果由本人承担。

学位论文作者签名：

日期： 年 月 日

上海交通大学

学位论文使用授权书

本人同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。

本学位论文属于：

☐ 公开论文

☐ 内部论文，保密 ☐ 1 年 / ☐ 2 年 / ☐ 3 年，过保密期后适用本授权书。

☐ 秘密论文，保密 ____ 年（不超过 10 年），过保密期后适用本授权书。

☐ 机密论文，保密 ____ 年（不超过 20 年），过保密期后适用本授权书。

（请在以上方框内选择打“√”）

学位论文作者签名：

日期： 年 月 日

指导教师签名：

日期： 年 月 日

摘 要

阿尔兹海默症 (Alzheimer's Disease, AD) 早期症状轻度认知障碍 (Mild Cognitive Impairment, MCI) 的筛查对于延缓病程、及时干预具有重大意义。现有基于磁共振成像 (Magnetic Resonance Imaging, MRI)、认知量表测试、生物标志物检查等传统诊断方法虽然精度较高,但因成本高昂、流程复杂难以应用与大规模人群筛查。针对这一问题,本文提出一种基于多模态知识蒸馏的 MCI 语音筛查框架,旨在利用多模态融合模型的知识增强单语音模型,以实现在仅使用语音输入的前提下提升筛查精度,满足低成本的大规模筛查需求。

具体而言,本文首先构建了多模态融合教师模型,针对输入的结构化语音特征、MRI 特征和认知量表测试等临床数据进行向量化,通过模态内注意力和模态间交叉注意力,结合对比学习和掩码重建实现多模态的高层语义对齐和特征表示。在此基础上,本文设计实现了软标签、硬标签和特征对齐联合优化的知识蒸馏框架,将多模态教师模型的跨模态病理知识迁移到仅依赖语音输入的学生模型中。

本文基于 ADNI-4 公开数据集及仁济医院提供私有数据集进行实验,结果显示多模态模型的各项指标显著优于各单模态模型,表明多模态融合对当前任务的有效性。此外,经过蒸馏的单语音学生模型性能优于原始语音单模态模型和各基线模型,验证了跨模态知识迁移的有效性。本文研究为开发低成本、规模化的 MCI 语音筛查工具提供了可行的技术方案。

关键词: 轻度认知障碍, 多模态融合, 知识蒸馏, 语音辅助诊断

ABSTRACT

Alzheimer’s Disease (AD) and the screening of its early-stage manifestation, Mild Cognitive Impairment (MCI), are of great significance for delaying disease progression and enabling timely intervention. Although existing traditional diagnostic methods based on Magnetic Resonance Imaging (MRI), cognitive scale tests, and biomarker examinations offer high accuracy, they are difficult to apply in large-scale population screening due to their high cost and complex procedures. To address this issue, this paper proposes an MCI speech screening framework based on multimodal knowledge distillation, aiming to enhance a unimodal speech model with the knowledge of a multimodal fusion model, thereby improving screening accuracy using only speech input and meeting the demand for low-cost, large-scale screening.

Specifically, this paper first constructs a multimodal fusion teacher model, which vectorizes structured speech features, MRI features, and cognitive scale test data, and achieves high-level semantic alignment and feature representation across modalities through intra-modal attention and inter-modal cross-attention, combined with contrastive learning and masked reconstruction. On this basis, a knowledge distillation framework with joint optimization of soft labels, hard labels, and feature alignment is designed and implemented, transferring the cross-modal pathological knowledge from the multimodal teacher model to a student model that relies solely on speech input.

Experiments conducted on the public ADNI-4 dataset and a private dataset provided by Renji Hospital demonstrate that the multimodal model significantly outperforms all unimodal models across various metrics, indicating the effectiveness of multimodal fusion for the current task. Moreover, the distilled unimodal speech student model surpasses the original unimodal speech model and all baseline models, validating the effectiveness of cross-modal knowledge transfer. This research provides a viable technical solution for developing low-cost, scalable MCI speech screening tools.

Key words: mild cognitive impairment, multimodal fusion, knowledge distillation, speech-assisted diagnosis

目 录

摘 要 I

ABSTRACT II

第一章 绪论 1

 1.1 引言 1

 1.2 本文研究主要内容 2

 1.3 本文研究意义 3

 1.4 本章小结 3

第二章 理论基础 4

 2.1 Transformer 4

 2.1.1 背景 4

 2.1.2 自注意力 4

 2.1.3 多头注意力 4

 2.1.4 交叉注意力 4

 2.1.5 位置编码 5

 2.1.6 残差连接和层归一化 5

 2.1.7 编码器-解码器架构 5

 2.2 知识蒸馏 5

 2.2.1 背景 5

 2.2.2 软标签 6

 2.2.3 中间层特征 6

 2.3 多模态对比学习 6

 2.4 掩码重建 6

 2.5 本章小结 7

第三章 方法设计 8

 3.1 多模态教师模型 8

3.1.1	输入数据	8
3.1.2	整体框架	9
3.1.3	数据处理	9
3.1.4	特征提取器	10
3.1.5	融合分类器	13
3.1.6	优化目标	13
3.2	单语音学生模型蒸馏	14
3.2.1	输入数据	14
3.2.2	整体框架	15
3.2.3	数据处理	15
3.2.4	特征提取器	15
3.2.5	分类器	16
3.2.6	优化目标	16
3.3	本章小结	17
第四章	实验评估	19
4.1	实验数据	19
4.2	评估方法	20
4.3	基线模型	23
4.3.1	外部基线模型	23
4.3.2	内部基线模型	24
4.4	实验设置	24
4.5	实验结果	24
4.5.1	ADNI-4 数据集	24
4.5.2	仁济医院数据集	26
4.6	消融实验	27
4.7	特征重要性评估	28
4.8	本章小结	28
第五章	全文总结	32
5.1	主要结论	32
5.2	研究展望	32

参 考 文 献	34
附 录	36
攻读学位期间学术论文和科研成果目录	37
致 谢	38

第一章 绪论

1.1 引言

阿尔兹海默症 (Alzheimer's Disease, AD) 是一种常见的神经退行性疾病, 症状包括记忆障碍, 失语, 失用, 失认以及视空间能力损害等。此外, 患者的抽象思维和计算力也会损害, 常伴随人格和行为的改变。轻度认知障碍 (Mild Cognitive Impairment, MCI) 被认为是 AD 的前驱阶段, 患者虽已出现超出正常衰老范围的认知功能下降, 但仍保留基本的日常生活能力。在文献^[1]中, 研究表明在 MCI 阶段, 通过生活方式的调整和运动疗法有望恢复认知功能, 但由于其早期症状往往隐匿, 导致患者错过最佳干预时机。当前临床诊断主要依赖磁共振成像 (Magnetic Resonance Imaging, MRI)、认知量表测试、生物标志物检查等检查手段, 但检查成本高、流程复杂、依从性低, 不利于大规模人群筛查。因此需要一种成本较低、便于普及的方法来辅助 AD 的初步诊断, 通过在大规模人群中筛查出可能的 AD 患者, 提示其进行后续更细致准确的医学诊断, 来同时满足规模化和资源友好的需求, 具有实用价值。

辅助诊断 AD 及 MCI 的现有研究使用了多种方法。在文献^[2]中, 研究者综合利用人口学信息、遗传易感基因 APOE 信息、语音数字标志物和血清生物标志物, 通过 XGBoost 构建模型。在文献^[3]中, 研究者综合利用认知量表评估、人口学信息和功能评估, 通过 XGBoost 构建模型。在文献^[4]中, 研究者比较了 4 种深度学习模型 InceptionV3、ResNet50、ResNet101 和 DenseNet169 利用 MRI 影像分类检测 AD 的效果, 显示出 MRI 影像在 AD 诊断中的有效性。但上述研究中基因信息、血清生物标志物、认知量表评估、MRI 影像获取的困难性使其不适用于大规模筛查任务。医学研究^[5]中显示, 语言功能障碍在 AD 疾病初期阶段即会出现, 表现在语义、句法、语音和韵律等方面。由于语音获取的便捷性, 通过语音进行大规模 MCI 筛查成为可能, 一系列研究也对通过语音检测 AD 及 MCI 进行了探索。在文献^[6]中, 研究者提出了一个基准模型, 分别提取声学特征和语言学特征进行 MCI 分类任务。部分研究基于语音识别转录的文本和在文本任务上表现良好的 BERT 预训练模型进行 AD 检测模型的构建。在文献^[7]中, 研究者利用领域已有知识, 提取语音转录文本中的语言特征, 对 BERT 模型进行微调。在文献^[8]中, 研究者利用预训练 BERT 模型提取语音转录的文本特征进行 AD 检测分类任务。在文献^[9]中, 研究者利用 BERT 模型和 TF-IDF 提取的转录文本特征进行融合用来分类。有研究考虑到语音转录的文本缺失了时间信

息，如发音速度和停顿，在文献^[10]中，研究者使用 w2v-BERT 2.0 模型直接对语音进行特征提取和分类任务，同时提出 MCI 症状可能只出现在语音的局部片段，因此采取 or 逻辑，即只要有一个局部片段被诊断为 MCI，整体就被分类为 MCI。

上述研究多采用单模态进行 AD 及 MCI 的诊断分类，随着多模态模型架构的发展，研究者开始探索多模态提取特征并融合用于医学任务的方法。在文献^[11]中，研究者通过可学习的查询向量，将图像信息转化为文本兼容的序列，经过微调，实现结合 3D 影像和文本的 MCI 诊断。在文献^[12]中，研究者通过对比学习实现医学图像和文本的对齐。在文献^[13]中，研究者整合图像、文本和音频模态，通过共注意力的中间融合和晚期融合进行模态间整合。在文献^[14]中，研究者通过对比学习和掩码重建构建图像和临床诊断信息的多模态模型用以 MCI 分类任务。

多模态模型通过综合各种模态的信息，在 AD 及 MCI 的诊断中表现出更好的能力。但多种模态信息中，除语音外的其余信息如 MRI 影像、认知量表测试、血清标志物等需依托专业设备或人员进行检测，难以在大规模筛查中获取。因此本课题提出通过跨模态知识蒸馏，利用多模态融合策略增强语音单模态模型在 MCI 判断分类上的能力，从而实现一个增强的仅语音输入的模型，降低大规模筛查成本，具有实用价值。相关研究中，研究^[15]提出一种跨模态框架将 MRI 教师的知识迁移到语音学生，研究^[16]提出一种跨模态框架将多模态教师模型（MRI 和正电子发射断层显像）知识迁移到 MRI 学生。相关研究中缺乏将多模态教师模型蒸馏到单语音模态学生模型的研究，本文研究具有一定探究价值。

1.2 本文研究主要内容

本文围绕多模态知识蒸馏获得加强的单语音模型开展研究，主要研究内容包括以下三个方面：

多模态融合模型构建：设计实现多模态融合神经网络作为知识蒸馏的教师模型。以语音特征、MRI 特征、认知量表测试、人口学信息等临床信息作为输入，实现一个二分类正常和 MCI 的分类模型。通过对比学习、掩码重建、模态间注意力和跨模态注意力促进模态内特征提取和模态间信息交换，以提高多模态融合模型的效果。

跨模态知识蒸馏框架构建：构建教师-学生蒸馏框架，教师模型为多模态融合模型，学生模型为单语音模型。通过软标签、硬标签和特征对齐三个优化目标联合蒸馏，以期实现多模态病理信息向学生模型的知识迁移，以提高学生单语音模态的诊断分类效果。

实验验证和系统评估：完成多模态融合模型和跨模态知识蒸馏框架的构建后，进行调优训练，获得较优的教师多模态模型，然后蒸馏出较优的学生模型。完成教师多模态模型对各单模态模型的对比实验，以及经过蒸馏的学生单语音模型对原始语音单模态模型和各基线模型的对比实验，在多个评估指标上进行评估。进行消融实验，明确蒸馏框架各设计的有效性。完成主要实验后，探究各输入特征对任务的重要程度，分析现有实验结果，最后评估现有实现中存在的不足和未来可能的改进方向。

1.3 本文研究意义

本文研究具有以下意义：

本文实现了一种多模态融合分类的网络框架，融合语音、认知量表、人口学、MRI 特征等多种模态信息，为未来多模态融合框架的设计实现提供了一定的参考价值。

本文实现了一种跨模态知识蒸馏框架，通过软标签、硬标签和特征对齐三个目标的联合蒸馏完成知识迁移，为未来跨模态知识蒸馏框架的设计实现提供了一定的参考价值。

本文探究了通过多模态知识蒸馏获得增强的单语音模型以用于进行 MCI 大规模筛查的方法，对 MCI 的低成本、大规模筛查提出了一种解决方案。未来的后续成果有机会在广泛人群中开展 MCI 筛查，及时进行医学干预治疗以减轻疾病带来的个人、家庭和社会负担，具有较高社会效益和实用价值。

1.4 本章小结

本章首先阐述了 AD 及 MCI 的临床特征和诊断现状，指出当前基于 MRI、认知量表和生物标志物等信息的检查手段虽诊断准确，但因成本高、流程复杂而不适用于大规模人群筛查。鉴于语言功能障碍在 AD 早期即可出现且语音获取便捷，通过语音进行 MCI 筛查具有突出优势。在回顾现有研究的基础上，本章梳理了从单模态语音分析到多模态融合诊断的发展脉络，指出现有多模态方法虽性能优越，但其依赖的 MRI、认知量表等模态信息难以在大规模筛查中获取。为此，本文提出通过跨模态知识蒸馏，将多模态教师模型蕴含的病理知识迁移至单语音学生模型，以实现仅需语音输入的增强型 MCI 筛查方法。随后，本章明确了三项主要研究内容，即多模态融合模型构建、跨模态知识蒸馏框架构建以及实验验证与系统评估，并从方法学参考价值、技术框架设计和大规模筛查应用三个层面阐述了本文的研究意义。

第二章 理论基础

2.1 Transformer

2.1.1 背景

Transformer 是一种基于注意力机制的神经网络结构，由文献^[17]提出。其克服了传统循环神经网络和卷积神经网络在长序列建模上的局限性，通过自注意力机制实现对序列中不同位置的依赖关系建模，一方面解决了长距离依赖问题，另一方面使得整个序列处理可以高度并行化，提升了训练效率。

2.1.2 自注意力

Transformer 的基本运算单元是缩放点积注意力。给定输入序列的查询矩阵 Q 、键矩阵 K 、值矩阵 V 、查询向量的维度（同键向量） d_k ，注意力计算为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-1)$$

2.1.3 多头注意力

单头注意力的表达有限，Transformer 引入多头注意力，允许模型在多个表示子空间中同时关注不同位置、不同类型的语义关系。其将查询、键、值分别投影到 h 个不同的低维子空间，在每个子空间独立执行注意力计算，最后将各头输出拼接并再次投影， W_i^Q 表示第 i 个头的查询权重矩阵， W_i^K 表示第 i 个头的键权重矩阵， W_i^V 表示第 i 个头的值权重矩阵， W^O 表示输出投影矩阵，用于将所有拼接后的头输出，线性变换回模型的主维度：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \quad (2-2)$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (2-3)$$

2.1.4 交叉注意力

交叉注意力是 Transformer 架构中实现两个不同序列之间信息交互的核心机制，与自注意力中查询、键、值均来自同一序列不同，交叉注意力的查询来自一个序列 Y ，而键和值来自另一个序列 X ：

$$\text{CrossAttn}(Y, X) = \text{Attention}(YW^Q, XW^K, XW^V) \quad (2-4)$$

2.1.5 位置编码

由于注意力机制对输入元素的处理是完全对称的、不包含序列顺序信息，Transformer 需要通过位置编码（Positional Encoding）将位置信息注入模型。原始论文采用正弦和余弦函数的固定编码， PE 为位置编码矩阵， pos 为序列位置， i 为编码向量维度索引， d_{model} 为编码向量维度：

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (2-5)$$

$$PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (2-6)$$

2.1.6 残差连接和层归一化

Transformer 的每个子层均采用残差连接并将结果送入层归一化：

$$\text{output} = \text{LayerNorm}(x + \text{Sublayer}(x)) \quad (2-7)$$

2.1.7 编码器-解码器架构

完整的 Transformer 由编码器和解码器堆叠而成。编码器对输入序列编码为连续表示，解码器则自回归地生成输出，每个时刻将已生成的输出作为输入，通过掩码注意力防止关注未来位置，再通过交叉注意力从编码器输出中检索源端信息。

2.2 知识蒸馏

2.2.1 背景

知识蒸馏是一种旨在将复杂、庞大模型（教师模型）所学习的知识迁移到结构精简、高效的小型模型（学生模型）中的模型压缩与知识迁移技术。其核心思想在于，通过让学生模型模仿教师模型的泛化方式而非仅仅记忆硬标签，从而在显著降低模型计算复杂度的同时尽可能维持模型性能。在文献^[18]中提出经典知识蒸馏框架，利用教师模型输出层经过 softmax 激活得到的各类别的概率分布作为软标签传递暗知识。文献^[19]补充提出蒸馏监督信号可以从输出层延申至中间隐藏层，学生模型通过模仿教师模型的中间层特征提取获得更强表征能力。

2.2.2 软标签

知识蒸馏引入温度超参数 T 对教师模型输出进行软化处理, 使输出概率分布变得更加平滑, 从而揭示类别之间的相对关系信息, 软化后的概率分布作为学生模型训练的软标签, z_i 为第 i 类的 logit:

$$q_i = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad (2-8)$$

2.2.3 中间层特征

选定教师模型中某一中间层 l 作为提示层, 输出特征图为 $F_t^{(l)}$, 其对应的学生模型中间层 l 作为引导层, 输出特征图为 $F_s^{(l)}$, $r(\cdot)$ 为可学习的线性变换函数, 用于将学生特征从原始维度映射到教师特征维度, 损失函数定义为:

$$\mathcal{L}_{\text{feat}} = \frac{1}{2} \|F_t^{(l)} - r(F_s^{(l)})\|_2^2 \quad (2-9)$$

2.3 多模态对比学习

多模态对比学习的本质目标是学习一个统一语义空间, 使得语义相似的多模态数据在该空间中距离相近, 语义无关的数据相互远离, 从而消除跨模态的语义鸿沟。文献^[20]构建了经典的双塔编码器结构, 两个模态的编码器输出特征, 分别通过独立的多层感知机投影头, 映射到维度相同的共享特征空间, 在共享特征空间中计算配对样本的相似度, 基于对比损失完成端到端的优化, 实现跨模态的语义对齐。对比学习优化的损失函数如下, z 为锚点样本的嵌入表征向量, z^+ 为与锚点样本语义一致的另一模态正样本表征向量, z_k^- 为第 k 个与锚点样本语义无关的另一模态负样本表征向量, K 为负样本总数, $s(\cdot)$ 为相似度度量函数, 通常采用余弦相似度, τ 为超参数温度系数, 控制对负样本的惩罚程度:

$$\mathcal{L}_{\text{InfoNCE}} = -\log \frac{\exp(s(\mathbf{z}, \mathbf{z}^+) / \tau)}{\exp(s(\mathbf{z}, \mathbf{z}^+) / \tau) + \sum_{k=1}^K \exp(s(\mathbf{z}, \mathbf{z}_k^-) / \tau)} \quad (2-10)$$

2.4 掩码重建

掩码重建是一种通过刻意遮挡输入数据的部分信息, 并训练模型根据可见区域来预测和还原被遮挡内容, 迫使模型学习数据的内在结构和语义的技术。文献^[21]中

提出的 BERT 模型将掩码重建应用于自然语言处理，证明其有效性。文献^[22]中提出的掩码自编码器 MAE 将掩码重建应用于图像领域，证明其有效性。掩码重建的核心优化目标是 minimized 被掩码位置的重建误差，通用损失函数如下， x_i 为输入序列第 i 个位置的真实值， $f(\cdot)$ 为编码器-解码器架构的重建模型，编码器负责对可见输入进行特征编码，解码器负责基于编码特征完成掩码区域的重建， $M_i = 0$ 表示被掩码的位置， L_{rec} 为模态适配的重建损失函数，文本模态通常采用交叉熵损失，图像、音频等连续信号模态通常采用均方误差损失：

$$\mathcal{L}_{\text{MR}} = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}, \mathbf{M} \sim p_M} \left[\sum_{i: M_i=0} \mathcal{L}_{\text{rec}}(f(\mathbf{x}_{\text{masked}})_i, x_i) \right] \quad (2-11)$$

2.5 本章小结

本章介绍了支撑本文研究的四项核心理论基础：Transformer 架构、知识蒸馏技术、多模态对比学习及掩码重建。

首先，本章从 Transformer 架构入手，阐述了其凭借自注意力机制革命性地解决了序列建模中的长距离依赖难题。通过引入多头注意力和交叉注意力，模型获得了在不同子空间捕获多样化语义关系及实现跨序列信息交互的能力。编码器-解码器架构的完善设计，使其成为后续众多先进模型的基础骨架。

其次，本章介绍了知识蒸馏技术。该技术通过软标签和中间层特征对齐，能有效地将笨重但强大的教师模型所学暗知识迁移至轻量化的学生模型，实现模型压缩与高效推理，其思想已成为模型轻量化的重要范式。

在此基础上，本章进一步探讨了多模态对比学习。该方法旨在通过学习一个统一的语义空间，将不同模态但语义关联的数据拉近，无关数据推远，从而跨越模态鸿沟。InfoNCE 损失函数为这种跨模态对齐提供了有效的优化目标。

最后，本章阐述了掩码重建方法。作为一种自监督学习范式，它迫使模型从被遮挡的输入中还原完整信息，从而学习到鲁棒的、深层的数据内在结构与语义表征，广泛适用于文本、图像等多种模态。

这四项技术中，Transformer 提供了灵活强大的宏观网络结构，知识蒸馏使得单模态学生模型能学习多模态教师模型迁移的知识，对比学习帮助模态信息对齐，使知识迁移更有效，掩码重建帮助挖掘模态内部的深层语义表征。本文后续的研究工作，建立在这些理论基础的综合运用之上。

第三章 方法设计

3.1 多模态教师模型




图 3-1 多模态教师模型

3.1.1 输入数据

本文使用的数据集包括三类模态数据：

语音表格特征：语音表格特征来源于受试者的语音记录，经预处理后提取为数值化的语音特征，涵盖声学特征、韵律特征、语谱特征等多维度语音属性，包括梅尔频率倒谱系数 MFCC、基频 F0、共振峰等。所有语音特征均为连续数值型变量，表征语音的声学与时序特性。

临床数据特征：临床数据特征来源于受试者完成的多种标准化神经心理学测试，包括简易精神状态检查 MMSE、蒙特利尔认知评估 MOCA 等，获得的特征均为数值化的得分。此外还包括受试者的人口学信息，包括年龄、性别、受教育程度等，同样为数值信息，例如性别被处理为 0/1 值。

MRI 特征：MRI 特征来源于受试者脑部结构磁共振成像后获得的 T1 加权结构像和 DTI 扩散张量成像经过计算提取后获得的数值信息，包括不同分区海马体积、皮

层厚度、水分子平均扩散率等。

3.1.2 整体框架

如图 3-1，本文参考文献^[14]提出的架构，多模态教师模型采用双分支架构。由于考虑到最终实现的是多模态教师模型对单语音模态学生模型的蒸馏，在设计架构时将数据划分为语音模态和非语音模态。临床数据特征和 MRI 特征合并到一条分支中进行处理，经过非语音编码器提取非语音特征向量 z_c 。语音表格特征在一条分支中进行处理，经过语音编码器提取语音特征向量 z_s 。语音特征 z_s 和非语音特征 z_c 进入融合分类器合并为组合特征 z_{concat} 后经过 MLP 分类器输出最终的二分类结果 MCI 和 CN。

3.1.3 数据处理

在模型训练前，对输入数据进行以下预处理操作：

样本对齐与清洗：基于唯一样本 ID，将语音表格、认知量表、数值化 MRI 表格进行样本级匹配，剔除 ID 不匹配、核心特征（如认知量表总分、语音核心声学特征）缺失的样本。

缺失值处理：对所有特征中的缺失值进行零填充处理。对于数值特征，使用 `np.nan_to_num` 函数将 NaN 值替换为 0，确保所有输入均为有效数值。

标准化处理：采用 Z-score 标准化方法对各模态特征进行归一化处理。标准化器仅在训练集上拟合，随后将拟合参数应用于验证集和测试集，避免数据泄露。具体而言，对每个特征维度 j ，计算训练集上的均值 μ_j 和标准差 σ_j ，然后对所有数据进行变换：

$$x'_j = \frac{x_j - \mu_j}{\sigma_j} \quad (3-1)$$

数据增强：在训练过程中，对表格特征应用两种数据增强策略：(a) 高斯噪声增强，以特征标准差的 0.05 倍为噪声标准差，向特征中添加随机高斯噪声；(b) 特征丢弃增强，以 10% 的概率随机将部分特征值置为零。增强操作以 60% 的概率随机触发，用于提升模型的鲁棒性和泛化能力。

数据划分：由于在数据集中存在同一受试者的多条样本，因此基于受试者标识符进行数据划分，确保同一受试者的所有样本仅出现在训练集、验证集或测试集中的某一个子集中，避免因同一受试者的不同样本分散在不同集合中而导致的信息泄露。划分时采用分层抽样策略，维持各类别样本在不同子集中的分布比例一致。




图 3-2 多模态教师模型编码器

3.1.4 特征提取器

如图 3-2，由于输入数据中，语音表格特征、临床数据特征、MRI 特征均为一系列数值量，可视作结构化表格数值数据，因此采用类似的特征提取器进行处理。

本文参考文献^[23]中提出的 FT-transformer (Feature Tokenizer Transformer)，对表格数据进行处理。特点在于使用了一个特征分词机制将表格特征转换为一组嵌入向量，即进行了单个数值特征的向量化，使得高度凝练的数值能被解读出更丰富的信息，并利用 transformer 的自注意力机制捕获特征间的复杂交互关系。

对于输入的数值型表格特征，特征分词器为每个特征维度分配一个可学习的线性投影层，将标量特征值映射到 d_{token} 维的嵌入空间。具体而言，给定输入特征 $x = [x_1, x_2, \dots, x_d]^T$ ，特征分词器生成一组特征令牌：

$$h_i = w_i x_i + b_i, \quad i = 1, 2, \dots, d \quad (3-2)$$

其中 $w_i b_i$ 第 i 个特征的线性投影参数。所有特征令牌堆叠形成令牌序列 $H =$

$[h_1, h_2, \dots, h_d]$, 作为后续 transformer 的输入序列。

为保留特征的位置信息, 引入可学习的位置嵌入 P , 将其添加到令牌序列中:

$$H' = H + P \quad (3-3)$$

特别的, 由于当前输入数据中的语音表格特征、临床数据特征中的数值量多是一些高度凝练的统计特征, 如梅尔频率倒谱系数 MFCC, 蒙特利尔认知评估 MOCA 分数, 适合进行向量化, 以充分挖掘其蕴含的丰富信息。而 MRI 特征是大量零散的数值信息, 因此不经过特征分词器, 而是直接作为向量与经过特征向量化的临床数据特征进行拼接合并, 作为后续 transformer 的输入序列。

3.1.4.1 特征编码器 (输出后续用于分类的特征)

特征分词后, 令牌序列进入 Transformer 编码器进行深层特征提取。Transformer 编码器由多个 Transformer 块堆叠而成, 每个块依次包含多头自注意力层、交叉注意力层和前馈神经网络层。特别的, 交叉注意力层在单模态编码器中被禁用, 在跨模态编码器中被启用, 从而使得模态内特征提取和模态间信息融合分离, 各自专注自身的任务, 并通过共享权重实现优化的共享。

多头自注意力层允许每个特征令牌关注序列中的所有其他令牌, 捕获全局特征依赖关系。对于输入 H' , 自注意力的计算过程为:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (3-4)$$

其中 $Q = H'W_Q, K = H'W_K, V = W_V$, 分别为查询、键、值矩阵, $d_k = d_{token}/n_{heads}$ 为每个注意力头的维度。

前馈神经网络层由两个线性变换和一个 GELU 激活函数组成:

$$\text{FFN}(x) = W_2 \cdot \text{GELU}(W_1x + b_1) + b_2 \quad (3-5)$$

每个子层均采用残差连接和层归一化, 以促进梯度流动和训练稳定性。

在编码器的输出端, 引入一个可学习的分类令牌 (CLS Token), 将其插入令牌序列的首位。编码后的 CLS 令牌被视为整个特征序列的聚合表示:

$$z = \text{Encoder}(h_{CLS} \oplus H')[0] \quad (3-6)$$

其中, z 为最终特征表示。

3.1.4.2 重建编码器（重建部分编码器：利用另一模态信息进行交叉注意力，与特征编码器权重共享）

该分支的输入，以固定掩码率 $\rho = 0.2$ 随机选择表格特征中的部分维度进行掩码操作。对于被掩码的位置，其特征值被替换为零：

$$x_j^{masked} = \begin{cases} 0, & \text{if } m_j = 1 \\ x_j, & \text{otherwise} \end{cases} \quad (3-7)$$

其中 $m_j \sim \text{Bernoulli}(\rho)$ 为掩码指示变量。为确保每个样本至少有一个特征被掩码，当所有特征均未被选中时，随机选取一个特征进行强制掩码。

被掩码的特征序列通过特征分词器转换为令牌嵌入，随后进入与特征编码器共享权重的重建编码器进行处理。重建编码器由多个 Transformer 块堆叠而成，每个块依次包含自注意力层、交叉注意力层和前馈神经网络层。在解码过程中，交叉注意力层以当前模态的被掩码特征令牌作为查询（Query），以另一个模态的编码特征作为键（Key）和值（Value），利用跨模态信息辅助重构，从而实现模态间的特征融合。对于当前模态被掩码令牌序列 H'_{mask} 和另一个模态输出编码特征令牌序列 $Z_{other} = [z_{other1}, z_{other2}, \dots, z_{otherd}]$ ，交叉注意力的计算为：

$$\text{CrossAttn}(H'_{mask}, Z_{other}) = \text{softmax}\left(\frac{Q_c K_c^\top}{\sqrt{d_k}}\right) V_c \quad (3-8)$$

其中 $Q_c = H'_{mask} W_{Q_c}$ 为当前模态生成的查询， $K_c = Z_{other} W_{K_c}$ 和 $V_c = Z_{other} W_{V_c}$ 分别为另一模态生产的键和值。

这种单向交叉注意力设计使得当前模态能够有选择性地整合来自另一模态的信息，同时保持自身的语义特性，反之亦然。交叉注意力层的输出经过残差连接和层归一化后，继续传递给前馈神经网络层进行非线性变换。

3.1.4.3 重建解码器（重建部分解码器）

掩码后的特征输入编码器获得潜在表示，解码器（重构层）则根据该表示尝试重建原始特征值。重构层由两层全连接网络构成：

$$\hat{x} = W_{r_2} \cdot \text{GELU}(W_{r_1} z_{mask} + b_{r_1}) + b_{r_2} \quad (3-9)$$

3.1.5 融合分类器

如图 3-1，融合分类器模块先将语音编码器输出的特征表示 z_s 和非语音编码器输出的特征表示 z_c 进行拼接，形成组合特征向量：

$$z_{concat} = [z_s; z_c] \quad (3-10)$$

组合特征通过一个多层感知机分类器进行二分类，分类器输出两个类别的预测概率：

$$\hat{y} = \text{softmax}(W_2 \cdot \text{ReLU}(W_1 z_{concat} + b_1) + b_2) \quad (3-11)$$

3.1.6 优化目标

多模态教师模型的训练采用多任务联合优化策略，总损失函数由以下三部分组成：

(1) 分类损失

为缓解类别不平衡问题，采用 Focal Loss 作为分类损失函数。Focal Loss 定义为：

$$\mathcal{L}_{cls} = -\alpha_t (1 - p_t)^\gamma \log(p_t) \quad (3-12)$$

其中 p_t 为模型对真实类别的预测概率， α_t 为类别权重（通过训练集各类别样本数量的倒数计算得到）， $\gamma = 2$ 为焦点参数。Focal Loss 通过降低易分类样本的损失权重，使模型更加关注难分类样本，有效缓解类别不平衡带来的训练偏差。

(2) 对比学习损失

采用跨模态对比损失，将语音特征与非语音特征视为跨模态的正样本对进行对比学习。给定批次内 B 个样本，计算两个模态间的余弦相似度矩阵：

$$s_{ij}^{s \rightarrow c} = \frac{z_{s,i}^T z_{c,j}}{\tau |z_{s,i}| |z_{c,j}|} \quad (3-13)$$

$$s_{ij}^{c \rightarrow s} = \frac{z_{c,i}^T z_{s,j}}{\tau |z_{c,i}| |z_{s,j}|} \quad (3-14)$$

其中， τ 为可学习的温度参数。

正样本对的定义基于样本的受试者标识符和疾病标签：同一受试者且相同标签的样本对被视为正样本。对比损失从语音到认知和从认知到语音两个方向计算：

$$\mathcal{L}_{s \rightarrow c} = -\frac{1}{|B_{valid}|} \sum_{i \in B_{valid}} \log \frac{\sum_{j \in \mathcal{P}_i} \exp(s_{ij}^{s \rightarrow c})}{\sum_{j=1}^B \exp(s_{ij}^{s \rightarrow c})} \quad (3-15)$$

$$\mathcal{L}_{c \rightarrow s} = -\frac{1}{|B_{valid}|} \sum_{i \in B_{valid}} \log \frac{\sum_{j \in \mathcal{P}_i} \exp(s_{ij}^{c \rightarrow s})}{\sum_{j=1}^B \exp(s_{ij}^{c \rightarrow s})} \quad (3-16)$$

其中, $\mathcal{P}_i$ 为与样本 i 具有相同受试者 ID 和标签的正样本索引集合, B_{valid} 为至少拥有一个正样本的样本集合。

总对比学习损失为两个方向的平均:

$$\mathcal{L}_{itc} = \frac{1}{2}(\mathcal{L}_{s \rightarrow c} + \mathcal{L}_{c \rightarrow s}) \quad (3-17)$$

(3) 重构损失 重构损失仅计算被掩码位置的平滑 L1 损失, 两个模态各自计算掩码重建损失:

$$\mathcal{L}_{recon}^s = \frac{1}{|\mathcal{M}_s|} \sum_{j \in \mathcal{M}_s} \ell_{SmoothL1}(\hat{x}_j^s, x_j^s) \quad (3-18)$$

$$\mathcal{L}_{recon}^c = \frac{1}{|\mathcal{M}_c|} \sum_{j \in \mathcal{M}_c} \ell_{SmoothL1}(\hat{x}_j^c, x_j^c) \quad (3-19)$$

$$\ell_{SmoothL1}(x, y) = \begin{cases} 0.5(x - y)^2, & |x - y| < 1 \\ |x - y| - 0.5, & \text{otherwise} \end{cases} \quad (3-20)$$

其中, $\mathcal{M}$ 为被掩码位置的索引集合。

总损失函数

将上述损失项加权组合, 得到教师模型的总体优化目标:

$$\mathcal{L}_{teacher} = \lambda_{cls} \mathcal{L}_{cls} + \lambda_{itc} \mathcal{L}_{itc} + \lambda_{recon} (\mathcal{L}_{recon}^s + \mathcal{L}_{recon}^c) \quad (3-21)$$

3.2 单语音学生模型蒸馏

3.2.1 输入数据

学生模型仅使用语音表格特征作为输入, 与教师模型训练阶段不同, 学生模型在推理时无需依赖临床数据特征和 MRI 数值信息, 从而降低了实际部署时对多模态数据的依赖。标签定义与教师模型保持一致, 采用二分类设置。




图 3-3 学生模型蒸馏框架

3.2.2 整体框架

如图 3-3，单语音学生模型蒸馏采用知识蒸馏框架，以训练完成的多模态教师模型作为教师网络，通过软目标监督和特征对齐两种策略，将教师模型的多模态知识迁移到仅使用语音模态的学生模型中。冻结的多模态教师模型提供软标签和中间层特征表示作为蒸馏目标。单模态学生编码器采用和教师模型语音分支相同的架构，独立提取语音特征。学生分类器基于语音特征进行二分类。最终蒸馏基于软标签、硬标签和特征对齐三个目标进行。

3.2.3 数据处理

学生模型的输入数据处理流程与教师模型一致，包括缺失值填充、Z-score 标准化和基于受试者 ID 的数据划分。训练阶段采用与教师模型相同的数据增强策略，以 60% 的概率对语音特征施加高斯噪声增强或特征丢弃增强。

3.2.4 特征提取器

学生模型的单模态编码器采用与教师模型语音分支完全相同的架构，包括特征分词器、位置嵌入、多层 Transformer 编码器、CLS 令牌聚合和输出投影层。编码过

程可表示为：

$$z_s^{stu} = f_{enc}^{stu}(x_s) \quad (3-22)$$

其中， f_{enc}^{stu} 为学生编码器。学生编码器从随机初始化开始训练，不同于教师模型语音分支的参数。这允许学生模型在学习过程中发展出适应单模态输入的特征提取模式。

3.2.5 分类器

如图 3-3，学生分类器采用与教师模型分类器中语音分支相同的结构，是一个两层的多层感知机：

$$\hat{y}^{stu} = \text{softmax}(W_2^{stu} \cdot \text{ReLU}(W_1^{stu} z_s^{stu} + b_1^{stu}) + b_2^{stu}) \quad (3-23)$$

3.2.6 优化目标

如图 3-3，学生模型的训练采用多层次的蒸馏优化策略，总损失函数包含以下三个部分：

(1) 硬目标分类损失

学生模型直接拟合真实标签的 Focal Loss：

$$\mathcal{L}_{cls}^{stu} = -\alpha_t (1 - p_t^{stu})^\gamma \log(p_t^{stu}) \quad (3-24)$$

其中 $p_t^{student}$ 为学生模型对真实类别的预测概率。通过硬目标监督确保学生模型具备基本的分类能力。

(2) 软目标蒸馏损失

利用教师模型的预测作为软目标，引导学生模型模仿教师模型的行为。首先将教师模型和学生模型的 logits 通过温度参数 T 软化：

$$p_i^{tea} = \frac{\exp(z_i^{tea}/T)}{\sum_j \exp(z_j^{tea}/T)} \quad (3-25)$$

$$p_i^{stu} = \frac{\exp(z_i^{stu}/T)}{\sum_j \exp(z_j^{stu}/T)} \quad (3-26)$$

蒸馏损失采用 KL 散度，衡量学生预测分布与教师预测分布之间的差异：

$$\mathcal{L}_{kd} = T^2 \cdot \text{KL}(p^{tea} | p^{stu}) \quad (3-27)$$

$$\text{KL}(p^{tea}|p^{stu}) = \sum_i p_i^{tea} \log \frac{p_i^{tea}}{p_i^{stu}} \quad (3-28)$$

其中 T 为蒸馏温度，乘以 T^2 是为了补偿温度缩放对梯度的影像。蒸馏损失使学生模型能够学习教师模型在类别间的软排序信息，这些信息包含比硬标签更丰富的类别间相似性知识。

(3) 特征级蒸馏损失

除了 logits 级蒸馏，本研究还引入特征级蒸馏，直接对齐学生模型与教师模型的中间层特征表示。采用均方误差损失衡量特征间的差异：

$$\mathcal{L}_{feat} = \frac{1}{d_{hidden}} \|z_s^{stu} - z_s^{tea}\|_2^2 \quad (3-29)$$

其中， z_s^{tea} 为教师模型语音分支输出的特征表示。特征级蒸馏强制学生模型学习与教师模型相似的内部表示，有助于保留教师模型中蕴含的丰富语义信息。

总损失函数将上述损失项加权组合，得到学生模型蒸馏的总体优化目标：

$$\mathcal{L}_{student} = \lambda_{cls} \mathcal{L}_{cls}^{stu} + \lambda_{kd} \mathcal{L}_{kd} + \lambda_{feat} \mathcal{L}_{feat} \quad (3-30)$$

3.3 本章小结

本章详细阐述了本文所提出的多模态知识蒸馏框架的设计细节，该框架旨在通过“多模态教师-单模态学生”的范式，实现仅依赖语音模态进行高精度认知障碍分类的目标。整体方法设计分为两个核心阶段：多模态教师模型的构建与训练，以及单语音学生模型的蒸馏迁移。

在第一阶段，本章首先定义了模型的多模态输入数据，包括语音表格特征、临床数据特征和 MRI 特征，并明确了数据预处理、增强及基于受试者的划分策略，以确保实验的严谨性。随后，设计了基于双分支架构的多模态教师模型。该模型利用特征分词器和 Transformer 编码器，分别通过独立的语音与非语音分支提取模态特定的深层特征，并在融合分类器中整合多模态信息以完成分类任务。为挖掘模态间的互补关系，本章引入了一种跨模态重建与对比学习的联合优化策略，通过掩码重建任务和跨模态对比损失，使模型能够捕获模态间的复杂交互和一致性表示，从而训练出高性能的教师模型。

在第二阶段，本章设计了基于知识蒸馏的单语音学生模型。学生模型仅以语音表格特征为输入，其架构与教师模型的语音分支相同。为将从多模态教师模型中习得的

丰富知识迁移至学生模型，本章设计了一个多层次蒸馏优化目标，该目标融合了来自真实标签的硬目标分类损失、来自教师软标签的软目标蒸馏损失，以及直接对齐教师与学生中间层特征表示的特征级蒸馏损失。此设计确保了学生模型在仅利用单一语音模态进行推理时，不仅能模仿教师模型的最终预测行为，还能学习其内在的特征表示结构，从而在摆脱对临床与影像数据依赖的同时，尽可能保持优异的分类性能。

综上所述，本章提出的方法设计，通过结构化的数据处理、双分支多模态编码器、跨模态交互学习及多层次知识蒸馏，构建了一个完整的从多模态教师模型训练到单模态学生模型蒸馏的框架设计。

第四章 实验评估

4.1 实验数据

本文实验数据来自 ADNI-4 (Alzheimer’s Disease Neuroimaging Initiative 4) 公开数据集^[24]以及上海交通大学医学院附属仁济医院提供的私有数据集。

ADNI-4 数据集提供的数据模态包括语音表格特征，临床数据特征和 MRI 特征。其中语音表格特征为受试者参与远程故事复述任务，通过设备录音回答问题后研究者从录音中提取好的 209 个数值化语音特征（词汇、句法等）和声学特征（语速、停顿等）。临床数据特征为 80 个数值化特征，包括人口学信息（年龄、性别、教育年限等）、神经心理学成套测验、多种认知量表评估数据。MRI 特征为 488 个研究者从 T1 加权结构像和 DTI 扩散张量成像计算获得的数值化特征，包括各区域海马体积、皮层厚度、白质微结构等。

ADNI-4 数据集中一个受试者可能对应多个样本数据。如表 4-1，整个数据集共有 346 个受试者，其中 249 个为正常 CN，97 个为 MCI。整个数据集共有 588 个样本，其中 437 个为正常 CN，151 个为 MCI。

仁济医院数据集提供的数据模态包括语音表格特征和临床数据特征。其中语音表格特征为受试者描述一张图片场景的录音经过阿里语音大模型提取的 99 个数值化语音特征（词汇、句法等）和声学特征（语速、停顿等）。临床数据特征为 13 个数值化特征，包括人口学信息（年龄、性别、教育年限等）、血液生物标志物（GFAP、NFL、Aβ40 等）、认知量表评估数据（MMSE、MoCA、CDR）。

仁济医院数据集一个受试者仅对应一个样本数据。如表 4-2，整个数据集共有 69 个样本，其中 13 个为正常 CN，56 个为 AD 或 MCI。

表 4-1 ADNI-4 数据集概况

统计层级	总数	CN（正常）	MCI（轻度认知障碍）
受试者级	346	249 (71.97%)	97 (28.03%)
样本级	588	437 (74.32%)	151 (25.68%)

表 4-2 仁济医院数据集概况

总数	CN (正常)	AD/MCI (认知障碍)
69	13 (18.84%)	56 (81.16%)

4.2 评估方法

由于实验使用的数据集较小,采用 5 折交叉验证进行评估。具体而言,将所有数据按受试者级进行 5 折分层划分,确保每一折的标签分布与整体数据集基本保持一致,每一折中,训练集与验证集按 8:2 的比例再次基于患者级分层划分,确保其中标签分布与整体数据集基本保持一致,测试集为当前折的留出患者数据。需要注意的是,所有划分均基于受试者 ID 进行数据集拆分,确保同一患者的所有样本归属同一集合,避免样本级数据泄露。

如表 4-3 为 ADNI-4 数据集分层划分的具体情况,如表 4-4 为仁济医院数据集分层划分的具体情况。

本研究采用准确率 (Accuracy, ACC)、宏平均召回率 (Macro Recall)、宏平均 F1 分数 (Macro F1-score) 以及受试者工作特征曲线下面积 (Area Under the ROC Curve, AUC) 作为模型性能评价指标。所有实验结果均基于 5 折交叉验证,并报告均值 $\pm$ 标准差。

基于二分类混淆矩阵的基础定义:真阳性 (TP)、真阴性 (TN)、假阳性 (FP)、假阴性 (FN),各指标的计算公式如下,其中 C 为类别总数,本研究中 $C = 2$:

准确率 (Accuracy, ACC): 预测正确的样本占总样本的比例,反映模型整体分类能力。

$$ACC = \frac{TP + TN}{TP + TN + FP + FN} \quad (4-1)$$

宏平均召回率 (Macro Recall): 各类别召回率的算术平均值,反映模型正确识别出的阳性样本占总真实阳性样本的比例。

$$Recall_{macro} = \frac{1}{C} \sum_{i=1}^C \frac{TP_i}{TP_i + FN_i} \quad (4-2)$$

宏平均 F1 分数 (Macro F1-Score): 精确率与召回率的调和平均值,综合反映模

型的精确性与完整性。

$$F1_{\text{macro}} = \frac{1}{C} \sum_{i=1}^C 2 \cdot \frac{\text{Precision}_i \cdot \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i}$$

(4-3)

受试者工作特征曲线下面积（Area Under the ROC Curve, AUC）：二分类任务中基于正类预测概率计算，综合反映模型的分类排序能力与泛化性，其中 n_0, n_1 分别为负类、正类样本数， $\mathbb{I}(\cdot)$ 为指示函数， $p_i p_j$ 为模型预测的正类概率。

$$AUC = \frac{1}{n_0 n_1} \sum_{i \in \text{正类}} \sum_{j \in \text{负类}} \mathbb{I}(p_i > p_j)$$

(4-4)

表 4-3 ADNI-4 数据集五折交叉验证划分详情（受试者级与样本级分布）

Fold	级别	集合	总数	Class CN	Class MCI
1/5	受试者级	Overall	346	249 (71.97%)	97 (28.03%)
		Train	220	159 (72.27%)	61 (27.73%)
		Val	56	40 (71.43%)	16 (28.57%)
		Test	70	50 (71.43%)	20 (28.57%)
	样本级	Overall	588	437 (74.32%)	151 (25.68%)
		Train	371	272 (73.32%)	99 (26.68%)
		Val	94	70 (74.47%)	24 (25.53%)
		Test	123	95 (77.24%)	28 (22.76%)
2/5	受试者级	Overall	346	249 (71.97%)	97 (28.03%)
		Train	221	159 (71.95%)	62 (28.05%)
		Val	56	40 (71.43%)	16 (28.57%)
		Test	69	50 (72.46%)	19 (27.54%)
	样本级	Overall	588	437 (74.32%)	151 (25.68%)
		Train	388	288 (74.23%)	100 (25.77%)
		Val	95	72 (75.79%)	23 (24.21%)
		Test	105	77 (73.33%)	28 (26.67%)
3/5	受试者级	Overall	346	249 (71.97%)	97 (28.03%)
		Train	221	159 (71.95%)	62 (28.05%)
		Val	56	40 (71.43%)	16 (28.57%)
		Test	69	50 (72.46%)	19 (27.54%)
	样本级	Overall	588	437 (74.32%)	151 (25.68%)

样本级

接下页

续表 4-3

Fold	级别	集合	总数	Class CN	Class MCI
4/5		Train	366	272 (74.32%)	94 (25.68%)
		Val	100	71 (71.00%)	29 (29.00%)
		Test	122	94 (77.05%)	28 (22.95%)
	受试者级	Overall	346	249 (71.97%)	97 (28.03%)
		Train	221	159 (71.95%)	62 (28.05%)
		Val	56	40 (71.43%)	16 (28.57%)
		Test	69	50 (72.46%)	19 (27.54%)
	样本级	Overall	588	437 (74.32%)	151 (25.68%)
		Train	373	276 (73.99%)	97 (26.01%)
		Val	89	65 (73.03%)	24 (26.97%)
		Test	126	96 (76.19%)	30 (23.81%)
5/5	受试者级	Overall	346	249 (71.97%)	97 (28.03%)
		Train	221	160 (72.40%)	61 (27.60%)
		Val	56	40 (71.43%)	16 (28.57%)
		Test	69	49 (71.01%)	20 (28.99%)
	样本级	Overall	588	437 (74.32%)	151 (25.68%)
		Train	370	281 (75.95%)	89 (24.05%)
		Val	106	81 (76.42%)	25 (23.58%)
		Test	112	75 (66.96%)	37 (33.04%)

表 4-4 仁济医院数据集五折交叉验证划分详情

Fold	集合	总数	Class CN	Class AD/MCI
1/5	Overall	69	13 (18.84%)	56 (81.16%)
	Train	44	8 (18.18%)	36 (81.82%)
	Val	11	2 (18.18%)	9 (81.82%)
	Test	14	3 (21.43%)	11 (78.57%)
2/5	Overall	69	13 (18.84%)	56 (81.16%)
	Train	44	8 (18.18%)	36 (81.82%)
	Val	11	2 (18.18%)	9 (81.82%)
	Test	14	3 (21.43%)	11 (78.57%)
3/5	Overall	69	13 (18.84%)	56 (81.16%)
	Train	44	8 (18.18%)	36 (81.82%)

接下页

续表 4-4

Fold	集合	总数	Class CN	Class AD/MCI
	Val	11	2 (18.18%)	9 (81.82%)
	Test	14	3 (21.43%)	11 (78.57%)
4/5	Overall	69	13 (18.84%)	56 (81.16%)
	Train	44	9 (20.45%)	35 (79.55%)
	Val	11	2 (18.18%)	9 (81.82%)
	Test	14	2 (14.29%)	12 (85.71%)
5/5	Overall	69	13 (18.84%)	56 (81.16%)
	Train	44	9 (20.45%)	35 (79.55%)
	Val	12	2 (16.67%)	10 (83.33%)
	Test	13	2 (15.38%)	11 (84.62%)

4.3 基线模型

4.3.1 外部基线模型

由于本研究数据集的限制，语音数据只有提取完成的语音特征和声学特征，经调研缺乏直接使用提取特征作为输入的深度学习相关研究，需经过一定结构上的调整转换。由于实验时间有限，因此本实验直接实现简单的机器学习方法和神经网络作为外部比较的基线模型，所有基线模型均在完全一致的 ADNI-4 语音数据集和 5 折交叉验证划分设置下完成训练和评估：

随机森林 (Random Forest)：集成 100 棵分类决策树，最大树深设置为 10，采用 balanced 类别权重平衡样本分布，其余参数采用 scikit-learn 默认设置。

XGBoost：设置迭代轮次 100、最大树深 6、学习率 0.1，通过 scale_pos_weight 参数处理类别不平衡问题，其余参数采用官方默认设置。

卷积神经网络 (CNN)：3 层一维卷积模块，卷积核尺寸为 3，输出通道数依次为 32、64、128，每层后经过 BatchNorm、ReLU 和最大池化，最终通过全连接层输出分类结果。

多层感知机 (MLP)：3 层全连接网络，隐藏层维度依次为 256、128、64，每层后经过 BatchNorm、ReLU 和 Dropout。

4.3.2 内部基线模型

本实验内部的基线模型采用仅通过语音数据训练的模型，一方面与多模态教师模型对比，评估多模态对任务的提升，另一方面与经过蒸馏的语音学生模型对比，评估蒸馏对性能提升的有效性。

4.4 实验设置

本实验的优化器、训练策略及超参数设置如下，各模型训练的设置均保持一致：优化器使用 AdamW 优化器，学习率设置为 $1e-4$ ，权重衰减为 $1e-4$ ，学习率调度采用 WarmupCosine 调度策略，预热比例为 10%，训练批次大小为 4，训练轮数为 50，采用基于验证集损失的早停策略，当验证损失连续 10 轮未下降时触发早停。模型 Transformer 编码器层数 N_d 为 6，注意力头数为 8，多模态教师模型损失函数各损失权重 $\lambda_{cls} = 1$ ， $\lambda_{itc} = 1$ ， $\lambda_{recon} = 1$ ，学生语音蒸馏损失函数各损失权重 $\lambda_{cls} = 1$ ， $\lambda_{kd} = 5$ ， $\lambda_{feat} = 0.01$ ，蒸馏温度 $T = 2$ 。实验采用前文 4.2 节所述的 5 折交叉验证方法进行训练评估，模型均在 NVIDIA GeForce RTX 3090 上进行训练。

4.5 实验结果

4.5.1 ADNI-4 数据集

4.5.1.1 多模态教师模型及单模态模型评估

为明确各模态信息在任务中的有效性，以选择最佳的教师模型，本实验训练了多种模态组合的模型，其中单语音模型作为后续比对的基线模型。各模型在 5 折交叉验证下测试集评估的性能如表 4-5 所示。

由结果可见，在单模态模型中，单 MRI 模型的表现较差，AUC 仅有 51.63%，难以进行有效区分，原因可能在于数据集中病人均为 MCI，而不是 AD 阶段，对早期认知障碍而言，大脑结构的变化还不够显著。而单语音模型表现出了筛查 MCI 的能力，AUC 达到了 72.53%，一定程度上说明在早期认知障碍阶段，患者的语言表现就可能出现区分性的异常，与医学研究^[5]的结果相符。单临床数据模型在单模态模型中表现出了最佳性能，AUC 达到 81.80%，说明现有医学临床诊断测试的有效性，符合一般认知。

在多模态模型中，各多模态模型性能均优于组成其的各单模态模型，语音-MRI

模型 AUC 为 72.68%，优于单语音模型和单 MRI 模型，语音-临床模型 AUC 为 83.83%，优于单语音模型和单临床数据模型，显示出多模态模型通过综合各种模态的信息能更有效地进行区分。值得注意的是，在 MRI 信息的有效性上，语音-MRI 模型相较于单语音模型，语音-临床-MRI 模型相较于语音-临床模型的 AUC、ACC、F1 指标均无明显提升，仅在 Recall 上有较明显提升（分别为 2.33% 和 2.14%），再次验证 MRI 信息对 MCI 筛查的有效性有限。但考虑到在大规模筛查任务中 Recall 指标对于漏诊的衡量重要性，最终选取语音-临床模型和语音-临床-MRI 模型均作为教师模型。

值得注意的是，在 5 折交叉验证的实验评估结果中标准差都较大，最大达到了 6.82%，可能原因在于数据集的数据量较小，而 MCI 的表现在不同受试者间可能存在特异性，导致模型难以学习到普遍规律。

表 4-5 不同模态组合的教师模型及单模态模型分类性能指标

模态组合	AUC	ACC	F1	Recall
语音（基线）	72.53%±2.30%	73.37%±2.60%	65.64%±2.40%	65.84%±1.71%
MRI	51.63%±4.86%	65.55%±5.78%	53.05%±3.15%	53.33%±3.22%
临床	81.80%±6.69%	76.97%±3.03%	70.48%±4.45%	71.89%±6.31%
语音-MRI	72.68%±4.10%	73.34%±4.40%	66.66%±5.45%	68.17%±5.70%
语音-临床（教师）	83.83%±6.82%	79.35%±4.31%	73.14%±6.31%	72.97%±5.94%
语音-临床-MRI（教师）	83.14%±4.91%	79.45%±2.63%	73.93%±2.83%	75.11%±2.33%

4.5.1.2 单语音学生模型蒸馏评估

由上述语音-临床模型和语音-临床-MRI 模型作为教师模型进行蒸馏训练出对应的单语音模型，并训练各基线模型进行比较，包括 random forest、XGBoost、CNN 和 MLP，以验证知识蒸馏对单语音模型表现提升的有效性。各模型在 5 折交叉验证下测试集评估的性能如表 4-6 所示。

由结果可见，通过语音-临床模型和语音-临床-MRI 模型作为教师蒸馏出的两个学生模型的表现接近，前者在 F1 和 Recall 的表现略好一些（分别为 0.01% 和 0.14%），在 AUC 和 ACC 的表现略差一些（分别为 0.56% 和 0.38%），说明 MRI 信息对单语音学生模型的指导效果有限。但两个蒸馏出的学生模型相较于只使用了语音数据的单语音模型性能都有一定提升，以语音-临床-MRI 蒸馏出的学生模型为例，AUC 上升了 1.38%，ACC 上升了 1.30%，F1 上升了 1.44%，Recall 上升了 1.83%，显示出知识蒸馏确实将另外模态的病理知识一定程度上迁移给了单语音学生模型，帮助其有了

更好的区分能力。但同时需要指出在当前实验中蒸馏带来的性能提升较有限，原因可能在于：首先，跨模态知识迁移本身的困难性，难以让单模态模型去真正学会其余模态带来的病理知识。其次，当前实验设计的不足，当前实验教师模型的结构设计和参数选择还有改进的空间，可能没有充分对齐两个模态的信息。以及，实验数据集的数据量较小，导致模型没有充分学习到区别 MCI 的病理规律。

同时可以看到，蒸馏出的学生模型在性能上是显著优于几个用于对比的基线模型的，以语音-临床-MRI 蒸馏出的学生模型为例，在 AUC 指标上相较于 random forest、XGBoost、CNN 和 MLP，分别上升了 5.05%、5.30%、4.87% 和 3.45%，显示出当前的架构设计在当前任务的有效性。

同样，值得注意的是，在 5 折交叉验证的实验评估结果中标准差都较大，最大达到了 6.37%，可能原因在于数据集的数据量较小，而 MCI 的表现在不同受试者间可能存在特异性，导致模型难以学习到普遍规律。

表 4-6 单语音蒸馏学生模型与基线模型的分类性能指标

模型	AUC	ACC	F1	Recall
语音（基线）	72.53%±2.30%	73.37%±2.60%	65.64%±2.40%	65.84%±1.71%
单语音学生（教师为语音-临床）	73.35%±2.87%	74.29%±2.63%	67.09%±3.62%	67.81%±3.50%
单语音学生（教师为语音-临床-MRI）	73.91%±3.84%	74.67%±3.76%	67.08%±4.67%	67.67%±5.47%
random forest	68.86%±4.51%	73.53%±2.37%	54.08%±1.51%	55.03%±1.06%
XGBoost	68.61%±3.59%	73.35%±3.07%	62.17%±4.09%	64.06%±4.98%
CNN	69.04%±6.37%	72.35%±3.04%	63.62%±5.40%	64.31%±6.18%
MLP	70.46%±5.09%	67.70%±4.17%	62.78%±3.67%	65.95%±4.29%

4.5.2 仁济医院数据集

由于仁济医院数据集数据量过小，仅作为补充实验进行，训练单模态临床数据模型、语音模型，多模态语音-临床教师模型以及单语音蒸馏学生模型。各模型在 5 折交叉验证下测试集评估的性能如表 4-7 所示。

由结果可见，由于数据集数据量过小，评估结果标准差非常大，最大达到了 19.91%，一定程度上说明了 MCI 区分在不同病人间的特异性较大。虽然较大的标准差降低了实验结果的说服力，但简单分析结果仍然可以获得与 ADNI-4 数据集实验在定性上类似的结论，临床数据模型在任务上的有效性高于语音模型（AUC 上升 17.27%），在蒸馏中经过教师模型的知识迁移，单语音学生模型的性能优于仅使用语

音数据训练的模型（AUC 上升 4.93%），一定程度上证明了蒸馏过程能迁移多模态病理知识给单模态学生模型以提升 MCI 分类效果。

表 4-7 仁济医院数据集各模型分类性能指标

模型	AUC	ACC	F1	Recall
语音（基线）	75.68%±19.91%	85.49%±4.54%	65.43%±17.48%	68.18%±16.79%
临床	92.95%±11.31%	91.43%±10.50%	87.61%±11.81%	88.03%±10.17%
语音-临床（教师）	92.95%±11.31%	90.00%±7.28%	84.62%±9.34%	84.70%±9.78%
语音（学生）	80.61%±11.91%	85.60%±6.27%	69.71%±16.01%	70.61%±16.42%

4.6 消融实验

为分析蒸馏架构中各组成部分的贡献，本研究在语音-临床-MRI 教师模型蒸馏单语音学生模型的基础上进行了消融实验。各模型在 5 折交叉验证下测试集评估的性能如表 4-8 所示。

消融蒸馏损失：进行了移除特征对齐损失（仅用硬标签 + 软标签）和移除软标签损失（仅用硬标签 + 特征对齐）的实验

消融特殊结构：进行了移除特征分词器，直接将输入数据作为特征向量输入后续 transformer 层的实验。

由结果可见，在 AUC 的评估上，消融特征对齐损失使其下降了 1.62%，消融软标签损失使其下降了 5.28%，消融特征分词器使其下降了 4.10%，显示出各设计对于任务性能提升的有效性，且发现软标签损失相较于特征对齐损失在蒸馏过程中起到了更大的帮助知识迁移的作用，说明了教师模型输出的软标签中包含的跨模态病理知识的传递有效性。

表 4-8 消融实验各模型分类性能指标

消融设置	AUC	ACC	F1	Recall
蒸馏学生语音模型（基线）	73.91%±3.84%	74.67%±3.76%	67.08%±4.67%	67.67%±5.47%
消融特征对齐损失	72.29%±2.05%	72.76%±3.59%	66.21%±2.99%	67.71%±3.03%
消融软标签损失	68.63%±3.27%	69.27%±1.93%	62.08%±4.21%	64.17%±5.71%
消融特征分词器	69.81%±3.47%	70.50%±2.97%	63.66%±3.69%	65.28%±3.38%

4.7 特征重要性评估

本研究还通过 Transformer 中的自注意力权重进行了输入数据中的特征重要性评估, 以在原理上尝试了解哪些具体特征在区分 MCI 中起关键作用, 获得一定医学上的指导意义。具体而言, 对每个测试样本, 提取最后一层 Transformer 中 [CLS] 标记对所有特征标记的注意力权重, 并在所有样本上平均, 得到每个特征的平均注意力评分。对 5 折交叉验证实验的所有模型, 计算各特征注意力权重均值, 得到最终的特征重要性排序。由高到低排序可以揭示对分类最有贡献的特征。由于模型架构中 Transformer 有两个分支, 分别获得语音模态以及临床数据 +MRI 模态的前 50 个特征重要性, 如图 4-1 和图 4-2 所示。

由图 4-1 结果可知, 对于语音特征, 重要性较高的特征是汇总的语音评分、声带震动频率 F0、平均停顿时长、声音共振峰 Formants、语音频谱结构 MFCC。

由图 4-2 结果可知, 对于临床数据特征, 重要性较高的特征是性别、MOCA 认知量表评分、临时记忆评分 AVTOT1、Ecog 评分 RMT_ecogpt。其中性别的高重要性可能是由于数据集划分时并没有考虑性别上的平衡或是数据集本身的不平衡导致的重要性虚高。对于 MRI 特征, 重要性较高的是左侧杏仁核体积 ST12SV。可以看到虽然 MRI 特征对区分 MCI 的重要性整体上不及临床数据特征, 但同样起到了一定的作用。

4.8 本章小结

本章围绕所提出方法在轻度认知障碍 (MCI) 筛查任务中的有效性开展了系统的实验评估。首先, 介绍了实验所使用的 ADNI-4 公开数据集与仁济医院私有数据集, 涵盖语音、临床及 MRI 等多模态信息, 并在受试者级严格划分数据集的基础上, 采用 5 折交叉验证以保证评估结果的可靠性与泛化性。同时, 选取准确率 (ACC)、宏平均召回率 (Macro Recall)、宏平均 F1 分数 (Macro F1) 以及 AUC 作为综合评价指标, 从不同角度刻画模型性能。

在多模态教师模型实验中, 结果表明: 单模态中临床数据表现最佳, 其次为语音数据, 而 MRI 模态在 MCI 阶段区分能力较弱; 多模态融合能够有效提升模型性能, 其中语音-临床模型取得最优综合表现, 验证了多模态信息互补的有效性。同时, MRI 模态虽对整体性能提升有限, 但在召回率上具有一定增益, 说明其在降低漏诊方面仍




图 4-1 语音特征重要性排序




图 4-2 临床 +MRI 特征重要性排序

具有潜在价值。

在知识蒸馏实验中，通过多模态教师模型向单语音学生模型迁移知识，学生模型在各项指标上均较基线语音模型取得稳定提升，说明蒸馏方法能够在一定程度上将跨模态的判别信息压缩至单模态模型中。此外，蒸馏模型整体性能显著优于传统机器学习方法及简单神经网络基线，验证了所提出方法的有效性。然而，性能提升幅度相对有限，反映出跨模态知识迁移仍存在一定挑战。

在仁济医院小规模数据集上的补充实验虽然受限于样本数量，结果波动较大，但整体趋势与 ADNI-4 数据集保持一致，进一步从侧面验证了方法的合理性与一定的泛化能力。

消融实验结果表明，各关键模块均对模型性能具有积极贡献。其中，软标签蒸馏损失对性能影响最大，说明教师模型输出的概率分布中蕴含了重要的跨模态知识；特征对齐损失与特征分词器结构同样对提升模型表达能力具有重要作用。

最后，通过基于自注意力机制的特征重要性分析发现，语音中的韵律与声学特征（如 F0、停顿、MFCC 等）以及临床认知量表特征（如 MoCA、记忆评分等）在 MCI 识别中具有较高贡献，MRI 特征虽整体权重较低，但部分结构性指标（如杏仁核体积）仍表现出一定区分能力，为模型决策提供了一定的可解释性支持。

综上所述，本章的实验评估表示所提出的多模态学习与知识蒸馏方法在 MCI 筛查任务中具有一定有效性，能够在保证模型轻量化的同时提升单语音模型的判别能力。但同时也存在数据规模较小、模型稳定性不足及跨模态知识迁移效率有限等问题，后续工作可从扩大数据规模、优化模型结构以及改进蒸馏策略等方面进一步提升模型性能与鲁棒性。

第五章 全文总结

5.1 主要结论

本文围绕轻度认知障碍 MCI 的低成本、大规模筛查问题，针对传统多模态诊断方法依赖昂贵设备、难以推广的局限性，提出了一种基于多模态知识蒸馏的语音筛查方法。通过构建多模态教师模型并将其知识迁移至单语音学生模型，实现了在仅使用语音输入的条件下提升筛查性能的目标。本文的主要结论如下：

(1) 本文设计并实现了一个融合语音特征、MRI 特征及临床数据的多模态教师模型。通过引入特征分词机制与 Transformer 编码结构，结合模态内自注意力与模态间交叉注意力，实现了多模态特征的深度融合与语义对齐。同时，结合对比学习与掩码重建策略，有效提升了模型的特征表达能力和鲁棒性。实验结果表明，多模态模型在各项评价指标上均显著优于单模态模型，验证了多模态融合在 MCI 筛查任务中的有效性。

(2) 本文构建了一个联合软标签、硬标签和中间层特征对齐的跨模态知识蒸馏框架，实现了多模态知识向单语音模型的有效迁移。通过蒸馏训练，学生模型在仅依赖语音输入的情况下，其分类性能明显优于原始语音模型以及多种基线模型，说明多模态教师模型中蕴含的跨模态病理信息能够有效提升单模态模型的判别能力。

(3) 本文在 ADNI-4 公开数据集及真实临床数据集上进行了系统实验评估。结果表明：多模态教师模型具有最优性能，而蒸馏后的单语音学生模型在性能与部署成本之间取得了良好的平衡，具备实际应用潜力。此外，通过消融实验验证了对比学习、掩码重建及多目标蒸馏策略的有效性；特征重要性分析进一步揭示了不同模态特征在 MCI 筛查任务中的贡献差异。

(4) 综合来看，本文提出的方法在保证较高筛查精度的同时，显著降低了对多模态数据的依赖，为构建低成本、可扩展的 MCI 早期筛查工具提供了一种可行的技术路径，具有一定的理论意义与实际应用价值。

5.2 研究展望

尽管本文在多模态知识蒸馏与语音筛查方向取得了一定进展，但仍存在一些不足，有待在后续研究中进一步完善和拓展：

(1) 数据规模与多样性有待提升。本文实验所使用的数据规模仍然有限,且不同数据源之间可能存在分布差异。未来可进一步引入更大规模、多中心的数据集,以提升模型的泛化能力和鲁棒性。

(2) 语音特征表达能力仍有提升空间。本文主要基于结构化语音特征进行建模,未充分利用原始语音信号中的时序信息。未来可结合端到端语音建模方法(如基于自监督预训练模型的表示学习),进一步挖掘语音中的深层语义信息。

(3) 蒸馏策略仍可进一步优化。当前蒸馏方法主要基于输出层和中间层对齐,未来可以探索更加精细的蒸馏机制,例如基于注意力分布对齐、关系蒸馏或动态蒸馏策略,以提高知识迁移效率。

(4) 模型可解释性有待增强。医学应用场景对模型的可解释性要求较高,未来可结合可解释人工智能方法,对模型决策过程进行分析,从而提高模型在临床应用中的可信度。

(5) 实际应用与系统落地仍需探索。本文主要集中于算法设计与实验验证,未来可结合移动设备或远程医疗系统,开发面向真实场景的 MCI 语音筛查系统,并开展前瞻性临床验证研究。

综上所述,本文的研究为基于语音的轻度认知障碍筛查提供了新的思路。随着多模态学习与跨模态蒸馏技术的不断发展,相关方法有望在实际医疗场景中得到更广泛的应用,为神经退行性疾病的早期干预提供有力支持。

参 考 文 献

- [1] SHIMADA H, DOI T, LEE S, et al. Reversible predictors of reversion from mild cognitive impairment to normal cognition: a 4-year longitudinal study[J]. *Alzheimers Research & Therapy*, 2019, 11(1): 24.
- [2] WANG J T, ZHI N, XU G, et al. Speech digital biomarker combined with fluid biomarkers predict cognitive impairment through machine learning[J]. *Alzheimer's Research & Therapy*, 2025, 17(1): 229.
- [3] MUNGAS D, GAVETT B, ROJAS-SAUNERO L P, et al. Machine learning diagnosis of cognitive impairment and dementia in harmonized older adult cohorts[J]. *Alzheimers Dement*, 2025, 21(8): e70508.
- [4] PALLWAI S, SINGH D K. Review and analysis of deep neural network models for Alzheimer's disease classification using brain medical resonance imaging[J]. *Cognitive Computation and Systems*, 2023, 5(1): 1-13.
- [5] MUELLER K D, KOSCIK R L, HERMANN B P, et al. Declines in Connected Language Are Associated with Very Early Mild Cognitive Impairment: Results from the Wisconsin Registry for Alzheimer's Prevention[J]. *Frontiers in Aging Neuroscience*, 2018, 9: 437.
- [6] LUZ S, DE LA FUENTE GARCIA S, HAIDER F, et al. Connected Speech-Based Cognitive Assessment in Chinese and English[C]//Proc. Interspeech 2024. 2024: 947-951.
- [7] BALAGOPALAN A, EYRE B, RUDZICZ F, et al. To BERT or not to BERT: comparing speech and language-based approaches for Alzheimer's disease detection[C]//Proceedings of Interspeech 2020. Shanghai, China: ISCA, 2020: 2167-2171.
- [8] SYED M S S, SYED Z S, LECH M, et al. Automated screening for Alzheimer's dementia through spontaneous speech[C]//Proceedings of Interspeech 2020. Shanghai, China: ISCA, 2020: 2222-2226.
- [9] VALSARAJ A, MADALA I, GARG N, et al. Alzheimer's dementia detection using acoustic & linguistic features and pre-trained BERT[C]//Proceedings of 2021 8th International Conference on Soft Computing & Machine Intelligence (ISCMI). Cairo, Egypt: IEEE, 2021: 171-175.
- [10] WANG Y, MATSUSHIMA T, MATSUSHIMA S, et al. Enhancing and exploring mild cognitive impairment detection with W2V-BERT-2.0[C]//Proceedings of 2025 IEEE International Conference on Acoustics, Speech, and Signal Processing Workshops (ICASSPW). Hyderabad, India: IEEE, 2025: 1-5.
- [11] CHEN Q, HONG Y. MedBLIP: Bootstrapping Language-Image Pretraining from 3D Medical Images and Texts[C]//Computer Vision – ACCV 2024: 17th Asian Conference on Computer Vision, Hanoi, Vietnam, December 8–12, 2024, Proceedings, Part III. Berlin, Heidelberg: Springer-Verlag, 2024: 98-113.
- [12] WANG Z, WU Z, AGARWAL D, et al. MedCLIP: contrastive learning from unpaired medical images and text[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP). Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2022: 3876-3887.
- [13] LEE B, SONG H J, PARK Y J, et al. Multimodal Alzheimer's disease recognition from image, text and audio[J]. *Scientific Reports*, 2025, 15(1): 29038.
- [14] CHEN Q, HONG Y. Alifuse: aligning and fusing multimodal medical data for computer-

- aided diagnosis[C]//Proceedings of 2024 IEEE International Conference on Bioinformatics and Biomedicine (BIBM). Abu Dhabi, United Arab Emirates: IEEE, 2024: 3082-3087.
- [15] AHIRE V, KUMAR Y, GIRARD A, et al. MINT: Multimodal Imaging-to-Speech Knowledge Transfer for Early Alzheimer's Screening[EB/OL]. 2026. <https://arxiv.org/abs/2602.23994>.
- [16] KWAK M G, MAO L, ZHENG Z, et al. A Cross-Modal Mutual Knowledge Distillation Framework for Alzheimer's Disease Diagnosis: Addressing Incomplete Modalities[J]. IEEE Transactions on Automation Science and Engineering, 2025, 22: 14218-14233.
- [17] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is All you Need[C]//Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017. Long Beach, CA, USA, 2017: 5998-6008.
- [18] HINTON G, VINYALS O, DEAN J. Distilling the Knowledge in a Neural Network[C]//NeurIPS Deep Learning Workshop 2014. Montreal, Canada, 2014.
- [19] ROMERO A, BALLAS N, KAHOU S E, et al. FitNets: Hints for Thin Deep Nets[C]//3rd International Conference on Learning Representations, ICLR 2015. San Diego, CA, USA, 2015.
- [20] RADFORD A, KIM J W, HALLACY C, et al. Learning Transferable Visual Models From Natural Language Supervision[C]//Proceedings of the 38th International Conference on Machine Learning, ICML 2021. Virtual Event: PMLR, 2021: 8748-8763.
- [21] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2019, Volume 1 (Long and Short Papers). Minneapolis, MN, USA: Association for Computational Linguistics, 2019: 4171-4186.
- [22] HE K, CHEN X, XIE S, et al. Masked Autoencoders Are Scalable Vision Learners[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2022. New Orleans, LA, USA: IEEE, 2022: 15979-15988.
- [23] GORISHNIY Y, RUBACHEV I, KHRULKOV V, et al. Revisiting Deep Learning Models for Tabular Data[C]//Advances in Neural Information Processing Systems 34: Annual Conference on Neural Information Processing Systems 2021, NeurIPS 2021. virtual, 2021: 18932-18943.
- [24] PETERSEN R C, et al. Alzheimer's Disease Neuroimaging Initiative (ADNI): clinical characterization[J]. Neurology, 2010, 74(3): 201-209.

符号与标记（附录 1）

攻读学位期间学术论文和科研成果目录

[1] 张三, 李四. …… (已录用)

致 谢

致谢主要感谢导师和对论文工作有直接贡献和帮助的人士和单位。致谢言语应谦虚诚恳，实事求是。

RESEARCH ON SPEECH SCREENING FOR MILD COGNITIVE IMPAIRMENT BASED ON MULTIMODAL KNOWLEDGE DISTILLATION

HCCI (Homogenous Charge Compression Ignition) combustion has advantages in terms of efficiency and reduced emission. HCCI combustion can not only ensure both the high economic and dynamic quality of the engine, but also efficiently reduce the NO_x and smoke emission. Moreover, one of the remarkable characteristics of HCCI combustion is that the ignition and combustion process are controlled by the chemical kinetics, so the HCCI ignition time can vary significantly with the changes of engine configuration parameters and operating conditions.